融合叙事语义进行金融波动预测

Yaxuan Kong*
英国牛津大学

Yoontae Hwang*
韩国釜山国立大学

Marcus Kaiser
德意志银行股份有限公司 英国伦敦

孔雅轩邮箱：yaxuan.kong@eng.ox.ac.uk yoontae.hwang@pusan.ac.kr
（此邮件地址无需翻译）

马库斯·凯泽@德意志银行.com

Chris Vryonides
德意志银行股份公司
英国伦敦

Roel Oomen
德意志银行股份有限公司 英国伦敦

Stefan Zohren
英国牛津大学

克里斯·弗里奥尼德斯@德意志银行.com罗尔·奥门@德意志银行.com

stefan.zohren@eng.ox.ac.uk

arXiv:2510.20699v1 [q-fin.CP] 23 Oct 2025

摘要

我们推出 M2VN：多模态波动率网络，这是一种基于深度学习的新型金融波动率预测框架，它将时间序列特征与非结构化新闻数据统一起来。M2VN 利用深度神经网络的强大表征能力来解决该领域的两个关键挑战：（一）对齐和融合异构数据模态，即数值金融数据和文本信息；（二）减轻可能破坏金融模型有效性的先知偏差。为实现这一目标，M2VN 结合了开源市场特征与由 Time Machine GPT 生成的新闻嵌入，Time Machine GPT 是最近推出的一种基于时间点的大型语言模型，从而确保了时间一致性。此外，引入了一个辅助对齐损失，以增强深度学习架构中结构化和非结构化数据的融合。大量实验表明，M2VN 一直优于现有基准，突显了其在动态市场中风险管理与金融决策方面的实际价值。

CCS 概念

· 计算方法 → 人工智能

关键词

多模态融合、时间对齐、前瞻偏差缓解、异构数据集成、表征学习

ACM 参考格式：

孔亚轩、黄勇泰、马库斯·凯泽、克里斯·弗里奥尼德斯、罗尔·奥曼和斯特凡·佐伦。2025 年。融合叙事语义进行金融波动预测。载于第六届 ACM 国际金融人工智能会议（ICAIF’25），2025 年 11 月 15 日至 18 日，新加坡。美国纽约：ACM，9 页。https://doi.org/10.1145/3768292.3771256

免责声明

本文所表达的观点仅为作者个人观点，并不一定代表德意志银行股份公司的观点。本文并非详尽无遗，也不构成任何财务或其他方面的建议。

两者都 作者对这项研究的贡献相同。

This work is licensed under a Creative Commons Attribution 4.0 International License. ICAIF’25, Singapore, Singapore

©2025 Copyright held by the owner/author(s).
ACM ISBN 979-8-4007-2220-2/2025/11 https://doi.org/10.1145/3768292.3771256

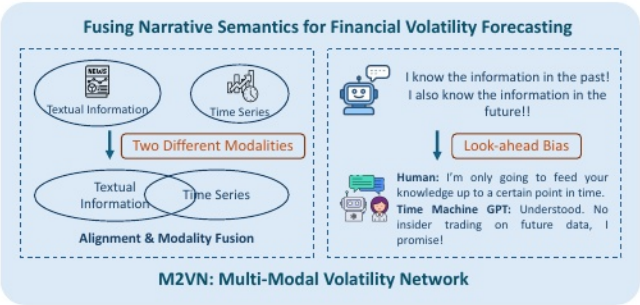

图 1：两种挑战的示意图：跨模态数据融合和消除先验偏见。

1 简介

预测金融市场波动是量化金融中的关键任务，在风险管理、衍生品定价和投资组合优化等方面有着广泛的应用[1, 3]。传统上，波动率预测方法主要依赖于直接从时间序列数据中提取的特征，例如历史价格、收益以及各种统计指标[8]。然而，自然语言处理（NLP）领域的最新进展以及大型语言模型（LLM）的出现，为将诸如新闻文章之类的外部文本信息纳入预测模型开辟了新的可能性[22， 23]。尽管在相关领域已经探索了文本增强的时间序列预测（TSF）[18， 20， 25]，但专门利用LLM生成的文本特征进行波动率预测的研究仍然有限。

大多数现有的研究通过词嵌入整合文本数据，并使用线性或自然语言处理模型来预测已实现波动率（RV）[5, 29, 30]。相比之下，将大型语言模型（LLM）提取的丰富、上下文感知信息与基于深度学习的时间序列模型在统一框架中进行整合的研究仍处于探索阶段。深度学习模型能够捕捉复杂的非线性关系，并能整合异构数据源，因此特别适合用于建模金融时间序列与文本信息之间的复杂动态关系。然而，迄今为止，这一领域的进展相对有限。

这种有限的探索在很大程度上可归因于金融时间序列与文本数据交叉领域所固有的若干独特挑战（如图 1 所示）。首先，金融新闻和时间序列数据属于不同的模态，这使得它们之间的融合颇具难度。

对齐和整合并非易事。具体而言，如何将文本信息与数值时间序列数据的交集有效地嵌入并融合到统一的嵌入空间中，是一个重大挑战。其次，利用新闻信息与大语言模型进行金融预测任务时，常常会引入“先知”偏差，即模型无意中纳入了未来的信息，从而影响其适用性和可靠性。

为应对这些挑战，我们提出了 M2VN：多模态波动率网络。M2VN 创新性地将传统的时间序列特征（源自开源的每日收盘价信息，包括开盘价、最高价、最低价、收盘价和成交量）与新闻数据相结合，其中新闻内容通过时间机器 GPT（TiMaGPT）[15] 进行嵌入，这是一系列专门设计用于减轻前瞻偏差的时点语言模型。为了有效地对齐这两种模态，我们引入了一个辅助对齐损失函数，这显著增强了模型在统一框架内融合文本和时间序列信息的能力。通过这种设计，M2VN 能够利用结构化的金融数据和非结构化的文本数据来提升波动率预测的性能。我们通过广泛的实验验证了 M2VN 的有效性，证明了其相较于现有基准的优越性能。

总之，我们的论文做出了以下关键贡献：

我们提出 M2VN：多模态波动率网络，这是一种新颖的框架，用于将新闻嵌入与时间序列数据对齐并融合，以完成金融波动率预测任务。

（2）我们评估了在相对价值预测中纳入丰富新闻文章所带来的增量价值，为在时间序列模型中加入上下文文本信息的好处提供了定量证据。

据我们所知，这是首次将 TiMaGPT [15] 应用于利用大语言模型缓解金融波动预测中的先验偏见的研究工作。

2 相关工作

我们回顾了有关金融波动预测和文本增强型时间序列预测的相关研究工作。

2.1 金融波动预测

本节首先回顾了用于波动率预测的主要模型，然后讨论了近期在引入外生变量以提高预测准确性方面的进展。

典型的波动率预测模型。传统的波动率预测一直以 GARCH 模型为主 16]，这类模型依靠每日收益率的平方来捕捉金融时间序列的动态变化。尽管简单直接，但这些模型往往受到基于每日收益的波动率代理指标的噪声干扰。基于高频日内数据的 RV 模型的出现显著提高了预测的准确性，尤其是引入了异质自回归（HAR）模型[6， 11， 13]之后。HAR 框架通过使用滞后的一日、一周和一月的波动率来预测当前波动率，以简单的线性结构捕捉波动率的持续性[8]。尽管高频数据具有优势，但其获取难度大且成本高，促使研究人员探索基于价格范围的估计器，如 Garman-Klass[17]、Parkinson [28] 和 Rogers-Satchell [31] 等，这些估计器利用每日开盘价、最高价、最低价和收盘价。近期的实证研究 [26] 表明，虽然基于高频数据的模型在极短期预测中表现更优，但对于更长的预测周期（例如一个月），预测精度的差异变得微不足道，这使得基于低频数据的方法在实际应用中既实用又有效。

波动率预测中的外生变量。为了进一步提高波动率预测的性能，近期的研究将外生变量引入到 HAR 模型中，从而形成了 HAR-X 框13]。这些外生预测变量通常包括隐含波动率指数、经济政策和股票市场不确定性指数、地缘政治风险指标、宏观经济指标以及特定资产的动量。通过引入历史波动率本身无法捕捉到的外部信息，这些额外的特征——其中许多以每日频率提供——已被证明能够提高样本外预测的准确性[24]。值得注意的是，一些研究发现，在某些情况下，低频的 HAR-X 模型能够与传统的高频方法相媲美[8]。然而，现有 9]仍主要集中在结构化数值数据或线性模型上，将非结构化文本来源与这些相关的时间序列特征相结合的研究相对较少[29, 30]。如何有效地协调和融合这些不同的模态这一问题在很大程度上仍未得到探索，这促使人们需要对多模态波动率预测进行系统研究。

2.2 文本增强的时间序列预测

本节回顾了将文本信息整合到时间序列预测（TSF）中的最新进展，重点关注了大型语言模型（LLMs）的应用以及金融背景下前瞻偏差的挑战。

用于时间序列预测的大型语言模型。有效整合外部文本信息已被证明能够提升时间序列预测的效果，例如通过将金融新闻情绪与市场走势相关联[34]。最近的研究表明，大型语言模型能够显著推进这一方法。例如，[19, 40]通过采用能够捕捉时间依赖性的 GPT-2 主干模型，展示了大型语言模型在一系列时间序列任务中的通用性。同样，[4， 18]强调了预训练大型语言模型的零样本预测能力，表明适当的标记化使得这些模型能够在无需专门针对特定任务进行训练的情况下，隐式地学习时间模式。此外，[20]提出了一种重新编程方法，将时间序列数据转换为更易于大型语言模型理解的格式，从而实现了最先进的预测结果。他们的补丁重新编程方法将时间序列补丁嵌入与自然语言表示对齐，增强了模型理解和推理时间序列数据的能力。这些研究共同表明了大型语言模型在推进时间序列预测领域方面的巨大潜力。

金融预测中的前瞻偏差。尽管基于大型语言模型的方法在一般领域取得了成功，但将其应用于金融时间序列时却因存在前瞻偏差的风险而变得复杂。当模型在训练或评估过程中无意中获取未来信息时，就会出现前瞻偏差，这会导致不切实际的乐观结果，并损害现实世界预测的可靠性[32]。为应对这一挑战，[21] 提出

使用匿名化数据来防止大型语言模型利用记忆中的未来信息；然而，这种方法可能会限制模型可用的文本数据的丰富性和具体性，从而可能限制其预测性能。为了更有效地减轻前瞻偏差，同时保留外部信息的实用性，[15] 引入了 TiMaGPT，这是一系列专门训练以严格保持时间一致性的即时点大型语言模型。通过确保模型在训练过程中对未来的事件或语言变化一无所知，TiMaGPT 为动态金融环境中的可靠时间序列预测提供了坚实的基础。

3 方法论

我们提出 M2VN：多模态波动率网络，其图形表示见图 2。

3.1 问题陈述

本小节给出了多模态波动率预测的正式问题表述，并确立了贯穿我们方法阐述所使用的数学符号。我们将该任务设定为一个有监督的序列到单值学习问题，目标是利用一段历史回溯窗口内的异质数据流来预测未来的金融波动率指标。我们的时间域由离散的交易日组成，用 T= 1, . . . ， T 进行索引。核心任务是在第 T 天收盘时，预测未来第 T + H 天的实际波动率，其中 H≥1 为预测时长。为实现这一目标，我们的模型会获取涵盖 [T − T + 1， T] 区间内 T 个前序交易日的数据。在每个时间点 T，输入为一个多模态元组 ZT= （X T， NT， MT） ∈ X，其中 X 为输入空间。此元组的每个分量代表一种不同的数据模态。

首先，$X_t = (x_{t - T + 1}, \ldots, x_t) \in \mathbb{R}^{T \times d_x}$ 表示定量的市场状态。每个特征向量 $x_\tau \in \mathbb{R}^{d_x}$ 是一系列指标的拼接，旨在捕捉市场动态的不同方面，包括历史波动率、价格趋势以及综合新闻信息。其构成形式化地表示为：

$$\mathbf{x}_\tau = [\underbrace{RV_\tau^{(d)}, RV_\tau^{(w)}, RV_\tau^{(m)}}_{\text{Realized Volatility}}, \underbrace{M_\tau^{(w)}, M_\tau^{(m)}, M_\tau^{(q)}}_{\text{Momentum}}, \underbrace{V_\tau^{(d)}}_{\text{Volume}}, \underbrace{\mathrm{VIX}_\tau^{(d)}}_{\text{VIX}}, \underbrace{C_\tau^{(d)}}_{\text{News Count}}]^\top \tag{1}$$

这里，RVτ（D） 、RVτ（W） 和 RVτ（M） 分别表示截至第 τ 天的每日、每周（5 日平均值）和每月（22 日平均值）的波动率。术语 $M_\tau^{(W)}$、 $M_\tau^{(M)}$ 和 $M_\tau^{(Q)}$ 分别是周度、月度和季度动量指标。交易量为 Vτ（D） 。最后，VIXτ（D） 是 VIX 指数的值，而 Cτ（D） 是第 τ 天相关新闻文章的数量。

其次，$N_t = (n_{t - T + 1}, \ldots, n_t) \in \mathbb{R}^{T \times d_n}$ 构成了定性信息状态。每个向量 $n_\tau \in \mathbb{R}^{D_N}$ is 是由预训练的基于 Transformer 的语言模型从第 τ 天发布的新闻标题和正文生成的密集向量 embedding，其维度 D_N corresponds 与该语言模型的输出维度相同。最后，$M_t = (m_{t - T + 1}, \ldots, m_t) \in \mathbb{R}^{T \times d_m}$ 包含时间标记，其中每个 $m_\tau \in \mathbb{R}^{d_m}$ 编码了与日历相关的信息（例如，星期几、月份），以捕捉已知的市场季节性。预测目标，即真实值，是第 $t + H$ 天的稳健波动率估计值，记为 $y_{t + H} \in Y \subseteq \mathbb{R}_{\geq 0}$ 。遵循已有的金融文献，我们将此目标定义为多个波动率估计值的聚合，以获得更稳定和全面的度量。具体而言，设 $V_{\tau P}$、$V_{\tau GK}$ 和 $V_{\tau RS}$ 分别表示天的 Parkinson [28]、Garman-Klass [17] 和 Rogers-Satchell [31] 波动率估计值。则目标变量构建为 $y_{t + H} = f_{agg}(V_{t + H}^{P}, V_{t + H}^{GK}, V_{t + H}^{RS})$，其中 $f_{agg}(\cdot)$ 是加权平均函数。

积分函数 [8] 。

我们的模型是一个具有参数 θ 的可学习函数 Φ，它将输入空间 X 中的输入实例 ZT 映射到预测的波动率 Y⊠T+H ∈Y。学习过程由一个双目标函数控制，该函数不仅确保预测的准确性，还促进定量和定性数据流之间的有意义的语义对齐。主要目标是预测损失，我们使用标准的均方误差（MSE）来定义它，以惩罚预测值与实际波动率之间的偏差：

$$\mathcal{L}_{\text{pred}}(\theta) = \mathbb{E}_{(\mathbf{Z}_t, y_{t+H})}[(\Phi(\mathbf{Z}_t; \theta) - y_{t+H})^2] \tag{2}$$

相应地，为了增强模型中间层融合信息的能力，我们引入了一个辅助对齐损失 Lalign，基于对比学习的原则。该目标鼓励在回溯窗口内相同时间步长的市场状态和新闻状态的中间表示相似，而与其他时间步长的表示不同（参见[25]）。设 hτ 和 hτ 分别为在时间步长 τ∈[T −T+ 1，T] 上定量和定性模态的潜在表示，该损失是通过 InfoNCE 目标来制定的，该目标最小化对齐对之间的交叉熵，并在一组负样本上进行。因此，最终的优化问题就是找到使这两个目标的加权和最小的参数 θ★：

$$\theta^\star = \arg\min_\theta \mathcal{L}(\theta) \quad \text{where} \quad \mathcal{L}(\theta) = \mathcal{L}_{\text{pred}}(\theta) + \lambda \mathcal{L}_{\text{align}}(\theta) \tag{3}$$

这里，λ> 0 是一个标量超参数，用于控制对齐任务的相对重要性。这种多任务学习范式对于引导模型发现市场动态与金融新闻叙述内容之间复杂的非线性相互作用至关重要。

所提出的模型、符号 Φ 用于解释输入数据（设计 X T、NT、Mis T tailored ）如何被处理，以使模型（Φ）有效运行，其参数（θ）以及双目标函数（Lpred、Lalign）将在以下各节中始终如一地使用。接下来，我们将详细说明为解决此处定义的学习问题而设计的模型的具体架构组件。

3.2 M2VN：多模态波动率网络

要从异质历史数据 ZT = （X T， NT， MT） 预测聚合相对波动率 RVY T+H，需要一种表示方法，该方法既要忠实于价格轨迹的统计规律，又要对金融叙事的语义内容敏感，还要考虑到日历驱动的季节性。因此，所提出的架构在紧密耦合的管道中处理这三种模态，其转换过程保持时间一致性并促进跨模态对齐，最终生成单一预测值 Y⊠T+H ∈Y。

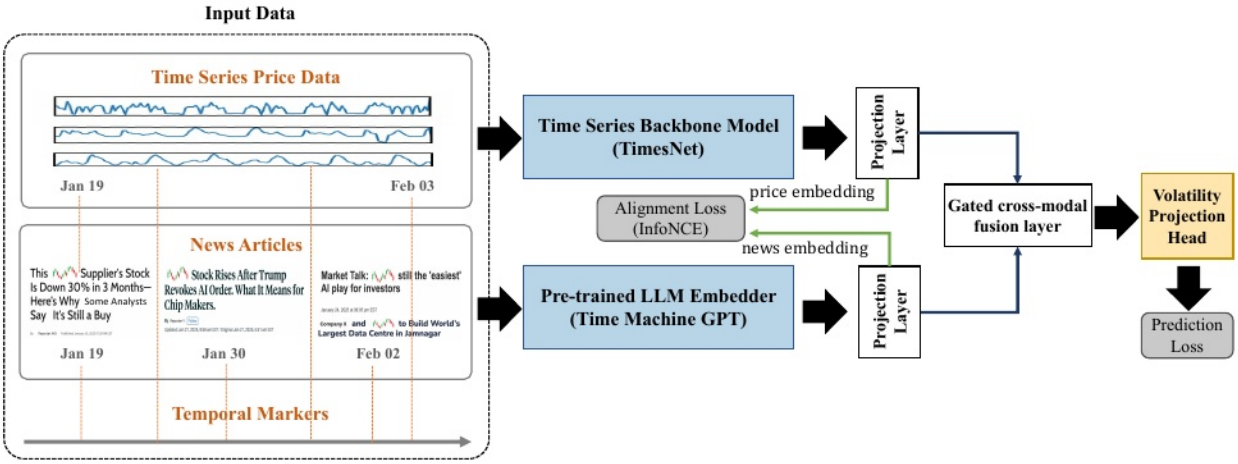

图 2：M2VN 的架构，这是一种用于金融波动率预测的多模态波动率网络。

形式上，输入张量为 XT∈RT×DX，预测张量为 NT∈RT×DN，时间张量为 MTT. ∈RT×DM，网络由参数 θ 定义，并且由恰好三个相互作用的组件按顺序处理这些输入。

多模态特征编码器。第一个组件将每种模态转换为宽度为 D 的公共潜在空间，同时保留完整的时序分辨率 T 。具体来说，一个可学习的映 RT×DX→RT×D 对定量信号进行嵌入，使用仿射归一化，随后采用周期谱操作符将轨迹分解为其主要频率通道。同时，一个投影 E_{news} LLM：RT×DN→RT×D 对转换器进行了蒸馏 -

推导出的新闻嵌入；其权重在不同日期间共享，因此驱动动态变化的是语义漂移而非尺度差异。最后，一个谐波嵌入 Etime： RT×DM→RT×D 编码日历特征 [37， 39]。编码器输出三个序列

$$\mathbf{h}_{1:T}^{\text{price}} = \mathcal{E}_{\text{price}}(X_t) \quad \mathbf{h}_{1:T}^{\text{news}} = \mathcal{E}_{\text{news}}^{\text{LLM}}(N_t) \quad \mathbf{h}_{1:T}^{\text{time}} = \mathcal{E}_{\text{time}}(M_t) \tag{4}$$

并且每个都属于 （RD）T。为简洁起见，我们将它们的联合拼接表示T ∈RT×3D 。此张量构成了进行时间推理的原始材料。

请注意，使用诸如 GPT-4.1 这样的现代语言模型来嵌入新闻流 N_T can 会虚假地提高预测准确性，因为该模型的训练语料库可能已经包含了未来的文章或事后知识。为了消除这种前瞻偏差，我们采用了 TiMaGPT [15]。对于每个日期 τ，嵌入 nτ 是使用 TiMaGPT 权重生成的，这些权重的知识截止时间已回溯到恰好在 τ 之前的一年。在实践中，我们在训练过程中逐年推进截止时间，冻结相应的参数，并将当天的新闻内容（通过将 τ 日期上发布的所有文章拼接而成）输入到这个冻结的模型中，以获得一个时间上忠实的向量表示。

潜在动态模块。第二个组件对整个时间范围内的长期依赖关系和跨模态交互进行建模。

(0)

在不借助因果截断的情况下实现 \(T + H\) [36]。设 \（h_1: T = h_1: T\）。一个由 \（L\） 个相同模块组成的堆栈对这些嵌入进行迭代细化，每个模块 \（T_ℓ: （R^{T×3d}） → （R^{T×3d}）\） 定义为

$$\mathcal{T}_\ell(\mathbf{h}) = \mathbf{h} + \mathcal{G}_\ell(\mathcal{C}_\ell(\mathbf{h})), \tag{5}$$

其中 Cℓ 是一个频谱卷积算子，它利用离散傅里叶变换来分离价格轨迹中能量最大的 K 个周期，然后在周期 - 通道网格上应用类似 Inception 的二维卷积。

波动率预测的一个关键难题在于区分出具有信息量的低频节奏（例如每周或每月的周期）和高频的随机噪声。为解决这一问题，采取了两步走的方法（见[36]）：

- 谱滤波。将潜在轨迹转换到傅里叶域，并保留能量最高的模式，从而分离出结构上最重要的成分。
- 《盗梦空间》风格的二维卷积。对滤波后的信号应用多尺度核，以捕获残余的跨时间交互作用。

在主干中选择顶级能量模式是一个基于原则的决策，而非经验法则。正如命题 3.1 所证明的那样，这能产生最佳的 k 项近似，从而最小化弗罗贝尼乌斯重构误差。这种方法在傅里叶分析、非线性逼近和压缩感知等领域是公认的原则，已证明选择 k 个最大的变换系数可提供最优近似[10, 12]。因此，这种方法施加了强烈的归纳偏差，促使网络专注于稳健的周期性结构，而非过度拟合偶然的噪声。这种内置的去噪机制能够显著提高泛化能力和稳定性。

给出以下结果是有启发性的，其证明可从标准结果[10， 12]中得出：

命题 3.1（最佳 K 项傅里叶逼近）。设 h = （⊠ $_0$, . ˙ ˙， ⊠ $_{T-1}$ ） ∈$(C^D)^T$and ，记其酉离散傅里叶变换为 bh = F h 。

$$\widehat{\mathbf{h}}_\omega = \frac{1}{\sqrt{T}} \sum_{t=0}^{T-1} h_t \, e^{-2\pi i \omega t/T}, \qquad \omega = 0, \ldots, T-1. \tag{6}$$

对于 $_1 \leqslant_K \leqslant_T$let $_{IK} \subseteq \{0, \therefore, _{T-1}\}$ 收集能量最大的 $_K$indices（如有并列情况，任意打破）并设置

$$(\mathcal{P}_k \widehat{\mathbf{h}})_\omega = \begin{cases} \widehat{\mathbf{h}}_\omega, & \omega \in I_k, \\ 0, & \omega \notin I_k. \end{cases} \qquad \mathbf{h}_k = \mathcal{F}^{-1}(\mathcal{P}_k \widehat{\mathbf{h}}). \tag{7}$$

然后 $h_K$minimises 近似误差

$$\mathbf{h}_k = \arg\min_{\tilde{\mathbf{h}}\in(\mathbb{C}^d)^T}\{\|\mathbf{h}-\tilde{\mathbf{h}}\|_F^2 \;\mid\; \|\mathcal{F}\tilde{\mathbf{h}}\|_0 \le k\}, \tag{8}$$

其中 ∥·∥ Fis 表示弗罗贝尼乌斯范数，而 ∥·∥ 0 表示非零傅里叶系数的个数。

证明。单位 DFT 的帕塞瓦尔恒等式给出

$$\|\mathbf{h}-\tilde{\mathbf{h}}\|_F^2 = \sum_{\omega=0}^{T-1}\|\widehat{\mathbf{h}}_\omega - \widehat{\tilde{\mathbf{h}}}_\omega\|_2^2 \qquad (\forall\tilde{\mathbf{h}}\in(\mathbb{C}^d)^T). \tag{9}$$

如果候选函数具有谱支集 S= {ω： bh⊠ω≠0} 且 |S| ≤K，则式 (9) 中对于 ω∈S 的求和项通过 h⊠ω= b b hω 得到最小化，而

对于 ω ∉ S 的最优选择是 hb⊠ω = 0。因此，对于此支撑集，可实现的最小误差等于

$$E(S) = \sum_{\omega\notin S}\|\widehat{\mathbf{h}}_\omega\|_2^2. \tag{10}$$

由于当Íω∈S∥hω∥2 2 增大时，E(S) 减小，所以 b 的支撑集
当且仅当基数 K 捕获了最大的 K 个能量值，即 S= IK 时，基数 K 才是最优的，此时的值为 Íω∉IK∥hω∥22。重建 b
通过逆离散傅里叶变换可得到上述声明的最小值解 hK。□

然后，函数 Gℓ 执行门控跨模态融合。给定从该模块输入中分离出的价格表示 r1：T 和新闻表示 t1：T，它计算一个门控 A1：T = σ（W G[r1：T； t1：T]） ∈（0， 1）T×1 并返回

$$\mathbf{z}_{1:T} = a_{1:T}\odot\mathbf{r}_{1:T} + (1-a_{1:T})\odot\mathbf{t}_{1:T}, \tag{11}$$

结合双线性及绝对差值交互作用，拼接——

（L）

映射并线性投影回 RD。因此，从最后一个模块中得出的整个序列 $h_{1:T}$ 包含了价格感知的新闻语义和新闻感知的价格谱。为了鼓励不同模态之间的语义一致性，我们提取对齐的嵌入向量

$$\mathbf{r}_{1:T} = P_{\text{price}}(\mathbf{h}_{1:T}^{(L)}), \qquad \mathbf{t}_{1:T} = P_{\text{news}}(\mathbf{h}_{1:T}^{(L)}), \tag{12}$$

其中，\（P^*\）：\（（R^{T \times 3d}） \rightarrow (R^{T \times da})\） 是线性投影，投影到宽度为 D_A 的对齐空间。在预备知识小节中介绍的 InfoNCE 损失 [27] 则实现为

$$\mathcal{L}_{\text{align}}(\theta) = \mathbb{E}[-\log\frac{\exp(\langle\mathbf{r}_\tau,\mathbf{t}_\tau\rangle/\tau)}{\sum_{\tau'}\exp(\langle\mathbf{r}_\tau,\mathbf{t}_{\tau'}\rangle/\tau)}], \tag{13}$$

其中，⊠·， ·⊠ 表示 RDA 中的内积，而 τ > 0 是一个学习到的温度参数。

波动率预测头。最后一个组件将融合后的潜在序列转换为点预测 Y⊠T+H 。对 h1：T （L）的价格通道切片应用一个时间投影 WP∈R（T+H）×T，得到一个扩展序列 h⊠1：T+H ∈R（T+H）×D，该序列将所学动态外推至预测地平线 H。我们保留最后一个位置，并将其通过仿射映射 WO： RD→Y 进行传递，从而获得

$$\hat{y}_{t+H} = W_o(\tilde{\mathbf{h}}_{T+H}). \tag{14}$$

确定性输出是合适的，因为目标 Y_{T+H} 被定义为三个波动率估计值的平滑聚合，因此其大部分不确定性集中在输入方面，而非测量方面。

网络参数是通过最小化联合目标函数来进行训练的。

$$\mathcal{J}(\theta) = \mathbb{E}_{(\mathbf{Z}_t,y_{t+H})}[(\Phi(\mathbf{Z}_t;\theta)-y_{t+H})^2] + \lambda\,\mathcal{L}_{\text{align}}(\theta), \tag{15}$$

其中第一项是前面定义的均方预测损失 Lpred，而 λ > 0 控制跨模态对齐的相对权重。采用具有自动微分功能的随机梯度下降法来求解 θ★= arg minθJ （θ）。

4 实验

现在我们展示实验结果，以全面证明 M2VN 在真实世界基准数据集上的性能。预处理后的数据集、原始新闻文章数据以及实现代码均可在 https://github.com/Yoontae6719/M2VN-Multi-Modal-Learning-Network-for-Volatility-Forecasting 公开获取。

4.1 实施细节

我们介绍了数据集的详细信息、基线模型、训练细节以及评估指标。

数据来源。我们构建了一个统一的每日面板，涵盖七只大型美国股票——可口可乐（KO）、康卡斯特（CMCSA）、康菲石油（COP）、吉利德科学（GILD）、默克公司（MRK）、耐克（NKE）和甲骨文（ORCL）。对于每只股票代码，我们从 FNSPID [14] 中提取了每日收盘价信息（开盘价、最高价、最低价、收盘价和成交量）以及相关新闻文章的全文。FNSPID 数据集 [14] 是一个开源资源，将金融新闻文章与相应的时间序列数据进行了整合。所有新闻文章都以结构化格式按日进行了时间对齐。由于新闻数据的可用性有限，上述七只股票是根据相关文章的数量进行选择的。

数据处理。新闻和时间序列数据均按时间顺序划分，训练区间为 2013 年 1 月 1 日至 2017 年 12 月 31 日，验证区间为 2018 年 1 月 1 日至 2020 年 12 月 31 日，严格独立的测试区间为 2021 年 1 月 1 日至 2023 年 12 月 15 日。新闻文档按时间对齐，只有在相应价格记录的前一天发布的文章才能进入该日模型的输入，从而避免任何前瞻性的信息泄露。

基准模型。为了评估 M2VN 的贡献，我们将它与十个强大的基准模型进行比较，这些基准模型涵盖了经典计量经济学和现代深度学习领域。经典模型组包括标准 HAR、HAR-X（OLS）、HAR-X（Lasso）和 HAR-X（Ridge），这些都是在波动率预测中广泛使用的异质自回归模型的变体[8]。现代深度学习模型组包括 Informer[39]、Autoformer[37]、DLinear[38]、TimesNet[36]、TimeXer[35] 以及 PAttn [33] 架构。对于所有三个 HAR-X 基准模型，我们首先通过主成分分析（PCA）降低每日新闻嵌入的维度，保留解释 95% 方差的主成分。这减轻了维度灾难，同时保持了计量经济学模型的简洁性。所有深度学习基准模型直接使用原始新闻嵌入。

训练详情。模型使用 12 个时间步长的序列进行训练，其中最后 2 个时间步长作为上下文标签，预测未来 1 个时间步长。所有深度学习基线和

方法	击倒		CMCSA		COP		吉尔德		MRK		耐克		ORCL	
	QLike	平均绝对百分比误差	QLike	平均绝对百分比误差	QLike	平均绝对百分比误差	QLike	平均绝对百分比误差	QLike	平均绝对百分比误差	QLike	平均绝对百分比误差	QLike	平均绝对百分比误差
HAR	0.0775	0.2932	0.0937	0.3317	0.0749	0.2982	0.0674	0.3290	0.0804	0.3106	0.0766	0.3179	0.0972	0.3219
HAR-X（普通最小二乘法）	0.0658	0.3507	0.0746	0.3317	0.0779	0.2889	0.0961	0.4447	0.1060	0.3705	0.0889	0.2946	0.1068	0.3185
HAR-X（岭）	0.0638	0.3484	0.0723	0.3388	0.0746	0.2873	0.0764	0.3942	0.0762	0.3361	0.0713	0.2946	0.0926	0.3082
HAR-X（套索）	0.0627	0.3535	0.0692	0.3216	0.0594	0.2818	0.0716	0.4043	0.0685	0.3475	0.0646	0.2873	0.0809	0.3047
告密者	0.1629	0.4028	0.1125	0.3403	0.1399	0.3519	0.1007	0.4035	0.1959	0.3311	0.1453	0.3017	0.2443	0.4125
Autoformer	0.1095	0.3756	0.1558	0.4036	0.1480	0.3625	0.1089	0.3622	0.0906	0.3420	0.1120	0.3297	0.2119	0.4302
D线性	0.0845	0.3371	0.0928	0.3355	0.0665	0.3083	0.0688	0.2977	0.0792	0.3174	0.0744	0.3103	0.1006	0.3614
TimesNet	0.0666	0.2943	0.0833	0.3177	0.0652	0.2839	0.0660	0.2852	0.0760	0.3065	0.0679	0.2905	0.0864	0.3182
PAttn	0.0699	0.3046	0.0805	0.3127	0.0603	0.2888	0.0678	0.2853	0.0699	0.3031	0.0695	0.3038	0.0959	0.3099
TimeXer	0.0661	0.3040	0.0807	0.3162	0.0589	0.3035	0.0673	0.2760	0.0797	0.2909	0.0671	0.2865	0.0849	0.3255
M2VN（我们的）	0.0589	0.2771	0.0769	0.3025	0.0552	0.2722	0.0630	0.2838	0.0679	0.3005	0.0594	0.2747	0.0696	0.3092

表 1：十种统计和深度学习模型对七只美国股票日波动率的样本外预测准确度。结果为拟似然损失（QLike）和平均绝对百分比误差（MAPE）。对于每只股票 - 指标组合，最佳模型以红色显示，次优模型以蓝色显示。数值为三次运行的平均值；标准差足够小，未列出。

消融	击倒		CMCSA		COP		吉尔德		MRK		耐克		ORCL	
	QLike	平均绝对百分比误差	QLike	平均绝对百分比误差	QLike	平均绝对百分比误差	QLike	平均绝对百分比误差	QLike	平均绝对百分比误差	QLike	平均绝对百分比误差	QLike	平均绝对百分比误差
M2VN	0.0589	0.2771	0.0769	0.3025	0.0552	0.2722	0.0630	0.2838	0.0679	0.3005	0.0594	0.2747	0.0696	0.3092
M2VN（D）无 Vτ	0.0610	0.2783	0.0812	0.3105	0.0580	0.2822	0.0659	0.2877	0.0701	0.3100	0.0648	0.3039	0.0774	0.3076
M2VN 无 Nτ	0.0641	0.2904	0.0866	0.3184	0.0599	0.3000	0.0632	0.2851	0.0692	0.3169	0.0638	0.2912	0.0780	0.3251

表 2：**M2VN** 预测中每日成交量特征（$V\tau^{(D)}$）的影响消融研究，以及新闻模态对 **M2VN** 波动率预测性能的影响。加粗表示每只股票-指标组合的最佳结果。

我们的 M2VN 模型采用 Adam 优化器，初始学习率为 3×10^{-4}，并使用余弦衰减。在验证集上进行早停以防止过拟合。在我们的模型中，超参数通过随机搜索进行选择，从以下网格中抽取 100 种配置：潜在维度 $D\in\{12, 24, 32, 64\}$，对齐维度 $D_\alpha\in\{3264, 128, 256\}$，温度 $\tau\in\{0.01, 0.03, 0.07\}$，Inception 隐藏宽度 $DI\in\{24, 32, 64, 128, 256, 512\}$ 以及 top-K 信号 $K\in\{4, 5, 6\}$。对于每个深度基线，都进行了等效搜索（具有特定于架构的范围），以确保公平比较。每个实验都使用三个随机种子重复进行，我们报告各次运行的平均值。

评估指标。模型性能通过平均绝对百分比误差（MAPE）和准似然损失（QLIKE）进行量化。MAPE 提供了一个易于解释且无量纲的百分比误差，对高估和低估的处理是对称的。QLIKE 基于高斯波动率模型的准对数似然，会在高波动时期对低估给予额外的权重。对于预测 $\hat{Y}_{T}$of 和实际波动率 Y_{T}over 的 Ntest 个数据点，它们的定义如下：

$$\mathrm{MAPE} = \frac{100\%}{n}\sum_{t=1}^{n}\left|\frac{y_t - \hat{y}_t}{y_t}\right|, \tag{16}$$

$$\mathrm{QLIKE} = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{y_i}{\hat{y}_i} - \ln\left(\frac{y_i}{\hat{y}_i}\right) - 1\right). \tag{17}$$

由于我们的模型直接预测波动率，因此在计算 QLIKE 时，我们将 $Y_{T}$and ?

?$\hat{}$ 均定义为标准差。虽然 QLIKE 指标通常应用于方差，但将其一致地应用于标准差，使其能够作为评估模型性能内部排名的稳健工具。它保留了对低估惩罚更重这一关键特性，这对我们的比较研究至关重要。

4.2 M2VN 对波动率预测有用吗?

为回答我们所提出的多模态框架是否能提升波动率预测这一核心研究问题，我们针对一系列强大的经典方法和深度学习基准模型进行了全面的实证评估。本节详细介绍了 M2VN 的样本外表现，其架构和学习目标在第 3 节中已有描述，该模型在七个真实世界的股票数据集上进行了测试。

定量结果见表 1。我们提出的模型 M2VN 表现始终强劲，在大多数股票指标设置中优于十项基准中的八项。具体而言，在 14 个评估设置中的 12 个（涵盖 7 只股票和 2 个指标）中，M2VN 获得最佳（以红色突出显示）或次佳（以蓝色突出显示）的结果。值得注意的是，它在十种情况（71.4%）中排名首位，并在绝大多数设置中位列前二。虽然 HAR-X（Lasso）基准在某些情况下也取得了不错的成绩，在两个设置（CMCSA–QLike 和 ORCL–MAPE）中获得最佳表现，但在大多数其他股票指标组合中，M2VN 的准确率要么与 Lasso 相当，要么更优，这凸显了其整体优势。与 TimesNet [36] 相比，

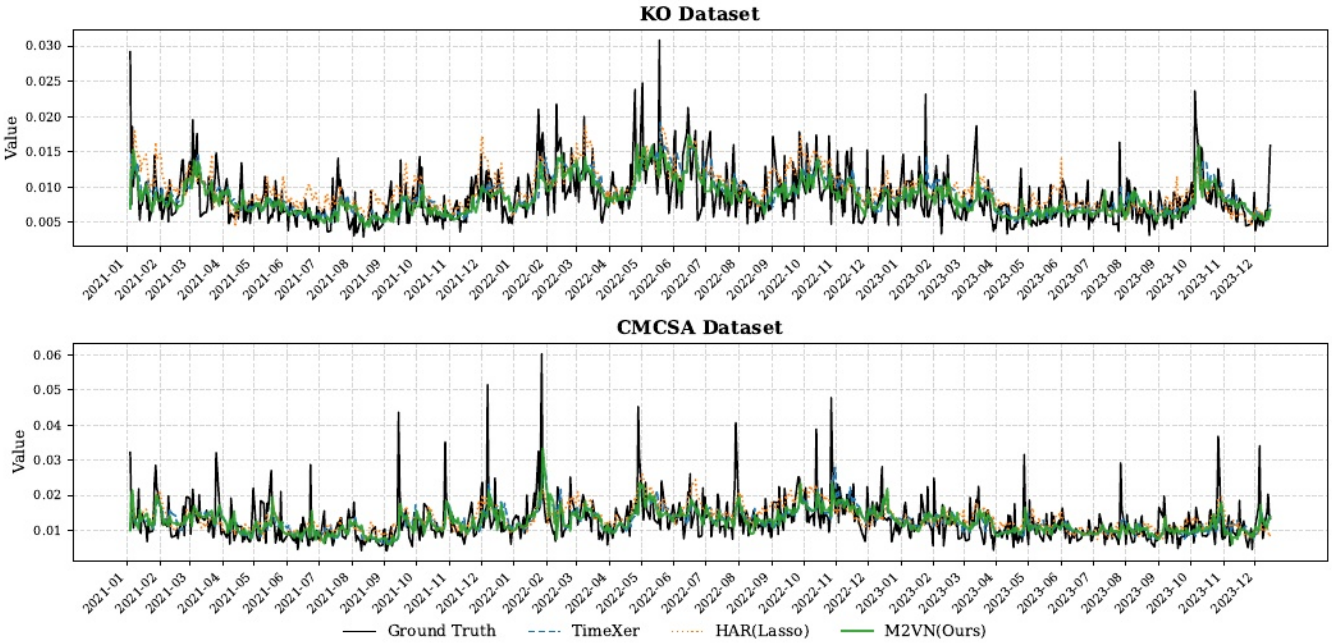

图 3：2021 至 2023 年测试期间 KO（上）和 CMCSA（下）数据集的样本外预测质量的可视化比较。**M2VN** 模型的预测值（绿色）与实际波动率（黑色）进行了对比，同时还有 HAR-X（Lasso）（橙色）和 TimeXer（蓝色）基准模型的预测值。与其它模型相比，**M2VN** 模型在追踪实际数据的波动和尖峰方面表现出了更出色的能力。

在去除骨干网络中的跨模态对齐损失 Lalign 后，平均 QLike 和 MAPE 分别下降了 11.7% 和 3.6%。

M2VN 的卓越性能可归因于几个关键的架构创新。首先，通过辅助对比对齐损失 (L_{align}) 明确融合定量市场数据和定性新闻叙述，使模型能够学习到比仅依赖价格数据的模型更丰富、更稳健的市场状态表示。其次，利用谱滤波分离波动率信号中主要周期成分的潜在动态模块（参见命题 3.1），有效地对输入序列进行了去噪。这种结构归纳偏差可能促使模型专注于持久、可预测的模式，而非过度拟合随机噪声，这是金融时间序列预测中的一个常见陷阱。这些实证结果表明，M2VN 所体现的架构选择适合波动率预测这一复杂任务。

4.3 成交量是新闻信息的替代指标吗?

为了探究市场活动与叙事信息之间的复杂关系，我们研究交易量是否可以作为新闻的替代指标。根据有效市场假说，新闻会迅速反映在价格中，而交易量往往反映出此类信息的到达和处理情况。这就引出了一个问题：新闻中所包含的信息是否已被更易获取的交易量数据所涵盖。

为了全面检验这一假设，我们对 M2VN 模型进行了每日有针对性的交易量消融实验（$V_{\tau(D)}$）。具体而言，我们将定量市场状态（X_T）和新闻嵌入（N_T）的模型性能与一个消除了交易量特征的相同模型进行了比较。在这种替代配置中，模型依靠新闻嵌入和其他市场变量来捕捉信息流。如果交易量仅仅是新闻的代理变量，那么从一个已经具备丰富新闻表示的模型中移除它，其性能变化应该很小。

在不考虑成交量的情况下，该实验的消融结果（见表 27 中的 M2VN W/O V在 $\tau_{(D)}$ 中）显示，所有七只股票的预测准确度均出现了具有统计学意义且一致的下降。完整模型（包含成交量，即标准 M2VN）在 28 个股票指标对中表现更优。平均而言，纳入成交量能使所有股票的平均绝对百分比误差（MAPE）降低 2.86±3.06%，QLike 指标降低 5.64±2.40%。

这些发现表明，交易量并非仅仅是新闻的替代指标，而是提供了补充信息。即便在丰富的文本新闻特征的基础上，纳入交易量仍能显著提高预测的准确性，这表明交易量捕捉到了市场动态的独特方面。这些方面可能包括投资者的分歧、流动性或市场关注的强度，而这些在新闻的语义内容中并未得到充分反映。因此，要开发出高精度的金融预测模型，将新闻叙述和交易量都视为不可或缺且互不冗余的信息来源至关重要。

4.4 新闻嵌入具有预测性吗?

为了确定新闻嵌入对 M2VN 模型预测能力的直接贡献，通过对比模型在有无新闻模态（N_T）情况下的表现进行了消融研究。表 2 展示了所有七只美国股票在两个关键指标上的样本外预测准确率：拟似然损失（QLike）和平均绝对百分比误差（MAPE）。结果明确表明，纳入新闻嵌入始终能提升预测性能。

在所有评估的股票和两个指标中，带有新闻嵌入的 M2VN 模型（标准 M2VN）显著优于不带新闻嵌入的模型（W/O N_T）。例如，在可口可乐（KO）的情况下，当纳入新闻后，QLike 从 0.0641 降至 0.0589，MAPE 从 0.2904 降至 0.2771。对于康卡斯特（CMCSA），也观察到了类似的改进，QLike 从 0.0866 降至 0.0769，MAPE 从 0.3184 降至 0.3025。值得注意的是，对于像康菲石油（COP）和甲骨文（ORCL）这样的股票，性能差距尤为显著，QLike 和 MAPE 均有大幅降低，这表明新闻内容为这些股票提供了非常有意义的信号。对于 COP，QLike 从 0.0599 改善至 0.0552，MAPE 从 0.3000 降至 0.2722。同样，对于 ORCL，QLike 从 0.0780 降至 0.0696，MAPE 从 0.3251 降至 0.3092。

尽管新闻整合带来的好处是普遍的，但不同股票的改善程度各不相同。例如，吉利德科学（GILD）的业绩提升相对较小（QLike 为 0.0632 对比 0.0630，MAPE 为 0.2851 对比 0.2838），这表明其波动性动态可能较少受到公开新闻叙述的影响，或者其价格变动主要由定量市场状态中捕捉到的其他因素所驱动。相反，像 COP 和 ORCL 这样收益较大的股票，其波动性特征可能对特定新闻事件或通过新闻传达的更广泛市场情绪更为敏感。这种差异可能源于特定行业的新闻影响、公司特定事件的频率，或者股票的一般信息效率。新闻嵌入可能通过提供有关市场驱动事件或情绪变化的及时定性见解来发挥作用，这些见解无法仅通过历史价格数据立即捕捉到。它们在某些情况下表现出的有效性，以及在其他情况下影响不那么显著，突显了定性信息与资产价格动态之间的相互关联关系。总体而言，纳入新闻嵌入的模型持续表现出色，这有力地证明了这种模态为 M2VN 多模态架构中的波动率预测提供了有意义的预测信号。

4.5 展示预测质量

为了补充表 1 中的总体指标，本节定性地将 M2VN 的样本外预测与真实值以及两个强大的基准模型——HAR-X（Lasso）和 TimeXer——在 CMCSA 和 KO 数据集（2021 年至 2023 年）上进行了比较，如图 3 所示。值得注意的是，虽然所有模型在预测极端单日波动冲击的确切幅度方面都存在困难（例如 2022 年初 CMCSA 的峰值），但 M2VN 相较于基准模型能更有效地捕捉这些峰值。相比之下，HAR-X（Lasso）和 TimeXer 倾向于生成过于平滑的预测，低估了尖锐的峰值，其中 HAR-X（Lasso）尤其在追踪事件后的衰减方面表现不佳。这导致在平静时期持续出现过度预测的情况，如 2022 年 8 月至 2023 年 1 月以及 2023 年 4 月至 6 月 KO 数据集中的 HAR-X（Lasso）所示。尽管 M2VN 可能会低估极端波动的绝对高度，但它能可靠地识别出急剧上升趋势的方向和时间，而基准模型往往反应迟缓或不明显。这种质的提升意义重大，因为预测罕见的波动冲击在金融建模中是一个众所周知的难题，由于此类事件在训练数据中代表性不足，而 M2VN 能够预测此类事件，这标志着相对于现有方法有了显著的进步。

5 结论

本研究引入了 M2VN，这是一种新颖的深度学习框架，能够有效地将结构化的金融时间序列与非结构化的新闻叙述统一起来，用于波动率预测。通过利用来自 TiMaGPT 的时间忠实的新闻嵌入以及通过对比损失实现的跨模态对齐，M2VN 解决了数据模态融合和前瞻偏差的关键挑战。在对美国大盘股的实验中表明，M2VN 在平均绝对百分比误差（MAPE）和 QLike 指标上均持续优于经典计量经济模型和深度学习基准模型，实现了更高的预测精度。消融研究进一步证实，交易量和新闻嵌入都提供了独特且互补的预测信号。这些发现突显了跨模态整合对于改进波动率建模和金融风险管理的价值。

致谢

作者们衷心感谢审稿人提出的富有洞察力且详尽的评论。Y.K. 感谢德意志银行股份公司的资金支持。

参考文献

[1] Carol Alexander. 2008. Market risk analysis, practical financial econometrics. Vol. 2. John Wiley & Sons.

[2] Torben G Andersen and Tim Bollerslev. 1998. Answering the skeptics: Yes, standard volatility models do provide accurate forecasts. International economic review (1998), 885–905.

[3] Torben G Andersen, Tim Bollerslev, Peter F Christoffersen, and Francis X Diebold. 2006. Volatility and correlation forecasting. Handbook of economic forecasting 1 (2006), 777–878.

[4] Abdul Fatir Ansari, Lorenzo Stella, Caner Turkmen, Xiyuan Zhang, Pedro Mercado, Huibin Shen, Oleksandr Shchur, Syama Sundar Rangapuram, Sebastian Pineda Arango, Shubham Kapoor, et al. 2024. Chronos: Learning the language of time series. arXiv preprint arXiv:2403.07815 (2024).

[5] Adam Atkins, Mahesan Niranjan, and Enrico Gerding. 2018. Financial news predicts stock market volatility better than close price. The Journal of Finance and Data Science 4, 2 (2018), 120–137.

[6] Francesco Audrino, Fabio Sigrist, and Daniele Ballinari. 2020. The impact of sentiment and attention measures on stock market volatility. International Journal of Forecasting 36, 2 (2020), 334–357.

[7] Kim Christensen, Mathias Siggaard, and Bezirgen Veliyev. 2023. A machine learning approach to volatility forecasting. Journal of Financial Econometrics 21, 5 (2023), 1680–1727.

[8] Adam Clements, Daniel Preve, and Clarence Tee. 2024. Harvesting the HAR-X Volatility Model. Available at SSRN 4733597 (2024).

[9] Adam Clements and Daniel PA Preve. 2021. A practical guide to harnessing the har volatility model. Journal of Banking & Finance 133 (2021), 106285.

[10] Albert Cohen, Wolfgang Dahmen, and Ronald DeVore. 2006. Compressed Sensing and Best k-Term Approximation. Technical Report, IGPM Report 260, RWTH Aachen University. https://www.igpm.rwth-aachen.de/Download/reports/pdf/IGPM260.pdf Technical report, later published in J. Amer. Math. Soc. 22(1):211– 231, 2009.

[11] Fulvio Corsi. 2009. A simple approximate long-memory model of realized volatility. Journal of Financial Econometrics 7, 2 (2009), 174–196.

[12] Mark A Davenport, Marco F Duarte, Yonina C Eldar, and Gitta Kutyniok. 2012. Introduction to compressed sensing. Cambridge University Press. 1–64 pages.

[13] Stavros Degiannakis and George Filis. 2017. Forecasting oil price realized volatility using information channels from other asset classes. Journal of International Money and Finance 76 (2017), 28–49.

[14] Zihan Dong, Xinyu Fan, and Zhiyuan Peng. 2024. Fnspid: A comprehensive financial news dataset in time series. In Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 4918–4927.

[15] Felix Drinkall, Eghbal Rahimikia, Janet B Pierrehumbert, and Stefan Zohren. 2024. Time machine GPT. arXiv preprint arXiv:2404.18543 (2024).

[16] Robert F Engle and Tim Bollerslev. 1986. Modelling the persistence of conditional variances. Econometric reviews 5, 1 (1986), 1–50.

[17] Mark B Garman and Michael J Klass. 1980. On the estimation of security price volatilities from historical data. Journal of business (1980), 67–78.

[18] Nate Gruver, Marc Finzi, Shikai Qiu, and Andrew G Wilson. 2023. Large language models are zero-shot time series forecasters. Advances in Neural Information Processing Systems 36 (2023), 19622–19635.

[19] Yoontae Hwang, Yaxuan Kong, Stefan Zohren, and Yongjae Lee. 2025. Decision-informed Neural Networks with Large Language Model Integration for Portfolio Optimization. arXiv preprint arXiv:2502.00828 (2025).

[20] Ming Jin, Shiyu Wang, Lintao Ma, Zhixuan Chu, James Y Zhang, Xiaoming Shi, Pin-Yu Chen, Yuxuan Liang, Yuan-Fang Li, Shirui Pan, et al. 2023. Time-llm: Time series forecasting by reprogramming large language models. arXiv preprint arXiv:2310.01728 (2023).

[21] Alex Kim, Maximilian Muhn, and Valeri V Nikolaev. 2024. Financial Statement Analysis with Large Language Models. Chicago Booth Research Paper Forthcoming, Fama-Miller Working Paper (2024).

[22] Yaxuan Kong, Yuqi Nie, Xiaowen Dong, John M Mulvey, H Vincent Poor, Qing-song Wen, and Stefan Zohren. 2024. Large Language Models for Financial and Investment Management: Applications and Benchmarks. Journal of Portfolio Management 51, 2 (2024).

[23] Yaxuan Kong, Yuqi Nie, Xiaowen Dong, John M Mulvey, H Vincent Poor, Qing-song Wen, and Stefan Zohren. 2024. Large Language Models for Financial and Investment Management: Models, Opportunities, and Challenges. Journal of Portfolio Management 51, 2 (2024).

[24] Burak Korkusuz. 2024. Beyond the S&P 500: examining the role of external volatilities in market forecasting. Review of Economic Design (2024), 1–28.

[25] Haoxin Liu, Shangqing Xu, Zhiyuan Zhao, Lingkai Kong, Harshavardhan Prab-hakar Kamarthi, Aditya Sasanur, Megha Sharma, Jiaming Cui, Qingsong Wen, Chao Zhang, et al. 2024. Time-mmd: Multi-domain multimodal dataset for time series analysis. Advances in Neural Information Processing Systems 37 (2024), 77888–77933.

[26] ⊠tefan Lyócsa, Peter Molnár, and Tomá⊠ V`yrost. 2021. Stock market volatility forecasting: Do we need high-frequency data? International Journal of Forecasting 37, 3 (2021), 1092–1110.

[27] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. 2018. Representation learning with contrastive predictive coding. arXiv preprint arXiv:1807.03748 (2018).

[28] Michael Parkinson. 1980. The extreme value method for estimating the variance of the rate of return. Journal of business (1980), 61–65.

[29] Navid Parvini and Hirbod Assa. 2025. Textual Regression for Realized Volatility: A Model for Long-Term Forecasting. Available at SSRN (2025).

[30] Eghbal Rahimikia, Stefan Zohren, and Ser-Huang Poon. 2021. Realised volatility forecasting: Machine learning via financial word embedding. arXiv preprint arXiv:2108.00480 (2021).

[31] L Christopher G Rogers and Stephen E Satchell. 1991. Estimating variance from high, low and closing prices. The Annals of Applied Probability (1991), 504–512.

[32] Suproteem K Sarkar and Kevon Vafa. 2024. Lookahead bias in pretrained language models. Available at SSRN (2024).

[33] Mingtian Tan, Mike Merrill, Vinayak Gupta, Tim Althoff, and Tom Hartvigsen. 2024. Are language models actually useful for time series forecasting? Advances in Neural Information Processing Systems 37 (2024), 60162–60191.

[34] Xingchen Wan, Jie Yang, Slavi Marinov, Jan-Peter Calliess, Stefan Zohren, and Xiaowen Dong. 2021. Sentiment correlation in financial news networks and associated market movements. Scientific reports 11, 1 (2021), 3062.

[35] Yuxuan Wang, Haixu Wu, Jiaxiang Dong, Yong Liu, Yunzhong Qiu, Haoran Zhang, Jianmin Wang, and Mingsheng Long. 2024. Timexer: Empowering trans-formers for time series forecasting with exogenous variables. Advances in Neural Information Processing Systems (2024).

[36] Haixu Wu, Tengge Hu, Yong Liu, Hang Zhou, Jianmin Wang, and Mingsheng Long. 2023. TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis. In International Conference on Learning Representations.

[37] Haixu Wu, Jiehui Xu, Jianmin Wang, and Mingsheng Long. 2021. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting. Advances in neural information processing systems 34 (2021), 22419–22430.

[38] Ailing Zeng, Muxi Chen, Lei Zhang, and Qiang Xu. 2023. Are transformers effective for time series forecasting?. In Proceedings of the AAAI conference on artificial intelligence, Vol. 37. 11121–11128.

[39] Haoyi Zhou, Shanghang Zhang, Jieqi Peng, Shuai Zhang, Jianxin Li, Hui Xiong, and Wancai Zhang. 2021. Informer: Beyond efficient transformer for long sequence time-series forecasting. In Proceedings of the AAAI conference on artificial intelligence, Vol. 35. 11106–11115.

[40] Tian Zhou, Peisong Niu, Liang Sun, Rong Jin, et al. 2023. One fits all: Power general time series analysis by pretrained lm. Advances in neural information processing systems 36 (2023), 43322–43355.