联邦学习在提升金融安全中的作用：综述

Cade Houston Kennedy
田纳西理工大学计算机科学系
美国库克维尔
chkennedy42@tntech.edu

Amr Hilal
田纳西理工大学计算机科学系
美国库克维尔
ahilal@tntech.edu

Morteza Momeni
田纳西理工大学财务系
美国库克维尔
mmomeni@tntech.edu

arXiv:2510.14991v1 [cs.CR] 7 Oct 2025

*摘要——随着*数字金融系统的不断发展，金融机 构对强大的安全性和隐私保护愈发重视。尽管传统机器学习模型在欺诈检测方面已证明有效，但它们往往需要集中访问敏感信息，从而危及用户数据。在诸如自动取款机和销售点系统等物联网金融终端中，这些设备会定期生成敏感数据并通过网络传输。联邦学习（FL）能够在不共享原始数据的情况下，实现跨机构的隐私保护型去中心化模型训练。联邦学习使银行之间能够跨部门协作，同时还能在物联网终端上进行跨设备学习。本综述探讨了联邦学习在增强金融安全方面的作用，并根据监管和合规风险暴露程度，对其应用进行了新颖的分类，从低风险暴露任务（如协作投资组合优化[16]）到高风险暴露任务（如实时欺诈检测[7]、[8]）均有涉及。与以往的调查不同，本研究审视了联邦学习在金融系统中的实际应用，探讨了其在监管合规方面的表现以及在欺诈预防和区块链集成框架方面的最新成果。然而，联邦学习在金融领域的部署并非一帆风顺。数据异质性、对抗性攻击以及监管合规等问题使得其实施远非易事。本研究回顾了当前的防御机制，并讨论了未来的发展方向，包括区块链集成、差分隐私、安全多方计算以及量子安全框架。最终，本研究旨在为探索联邦学习在推进安全、隐私合规金融系统方面潜力的研究人员提供资源。

I. 简介

在过去十年中，机器学习技术已在医疗保健、交通运输和制造业等多个不同行业得到应用。最近，金融行业也开始将该技术用于多种不同的场景，其中最突出的是欺诈检测[29] - [31]、贷款审批[32]和股市分析[33]。然而，这种技术的发展严重依赖于丰富且高质量的数据集来训练出高精度的机器学习模型[1]。对数据的需求使得获取这些模型所需的数据成为重点。但由于金融数据的高度敏感性，收集大规模数据集往往需要金融机构之间的合作。这种机构间的数据共享带来了有关数据收集、存储和使用透明度的重大隐私和安全挑战[2]。

联邦学习（FL）是一种机器学习框架，它为在用户特定数据上进行分散式训练开辟了道路，在这种情况下，客户端数据永远不会离开设备或机构。特别是跨机构联邦学习指的是少数受信任机构（如银行或金融公司）之间的协作，它们共同训练一个共享模型，而不会暴露各自的本地数据集。相比之下，跨设备联邦学习则是在边缘层面应用联邦学习，例如移动银行应用程序或销售点终端，使金融机构能够在不从单个终端提取敏感数据的情况下进行实时预测。这在物联网驱动的金融设备生成大量高度敏感数据的情况下尤为重要。

鉴于某些金融应用（如贷款审批）对宏观经济的依赖性[34]，机构可以从这种集体智慧中获益，从而做出更明智的决策。但这种训练方式也面临诸多挑战，尤其是在考虑联邦学习的快速发展时。如图 1 所示，在标准的联邦学习协议中，服务器将全局模型发送给选定的机构作为本地模型，随后再将这些机构训练后的模型更新发送回服务器。之后，服务器通过聚合本地更新来更新全局模型，然后再发送回各机构。

在整个过程中，各机构的数据只能由该机构访问，这从本质上确保了数据的隐私性。然而，近期的研究发现联邦学习存在若干安全风险，例如数据重建和后门攻击[4]、[5]。尽管面临这些挑战，但利用联邦学习来增强金融安全方面已取得了一些令人鼓舞的进展。例如，有研究探索了将区块链集成到跨部门框架中，以加强隐私和问责制[6]。在欺诈检测领域，联邦学习通过利用多个机构数据的集体见解，而无需损害个人用户隐私，已显示出显著提高准确性的潜力[7]。此外，还有研究展示了联邦学习在金融安全领域的更广泛影响，包括通过基于区块链的框架检测伪造数据[8]、通过联邦迁移学习解决客户间数据异质性问题[9]，以及将量子计算与联邦学习相结合以提供先进的金融服务[10]。

©2025 IEEE. The final published paper is copyrighted by IEEE and should be cited as: Cade Kennedy, Amr Hilal, Morteza Momeni, “The Role of Federated Learning in Improving Financial Security: A Survey,” *IEEE Global Conference on Artificial Intelligence & Internet of Things (GCAIoT)*, 2025, pp. 1–8. Personal use of this material may be permitted and permission from IEEE must be obtained for all other uses.

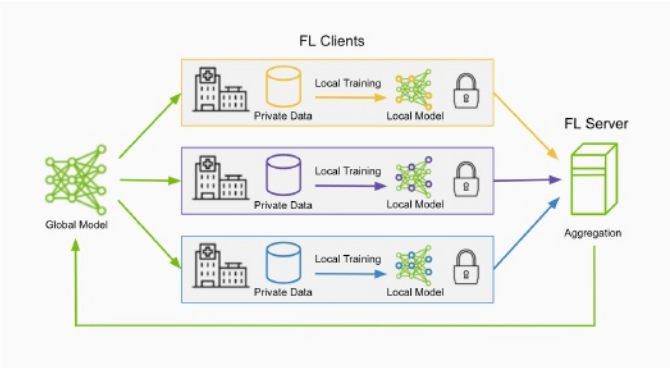

图 1. 联邦学习协议的可视化表示[3]。联邦学习的每一轮都从具有初始化权重的全局模型开始。然后，联邦学习服务器将全局模型发送给客户端。接下来，客户端在本地使用特定于数据孤岛或设备的数据进行训练，并仅将本地更新提交给联邦学习服务器。随后，联邦学习服务器对这些本地模型执行某种聚合方法以更新全局模型。最后，联邦学习服务器将聚合后的模型发送回客户端。

鉴于该领域的发展以及其跨学科的特性，有必要进行一次全面的综述来整合知识，并探讨新兴趋势和挑战。本综述旨在填补这一空白，通过整理和分析金融安全领域中有关联邦学习的现有研究，并以一种新颖的方式根据其监管和合规风险程度对相关方法进行分类：

- 低风险敞口：例如，信用风险评估
- 中度风险：例如，贷款审批
- 高曝光度：例如，实时欺诈检测

通过这种结构化的调查方式，旨在根据金融应用的敏感性和关键性程度，阐明各种联邦学习方法的适用性、有效性和局限性。这种分类不仅有助于研究人员和从业者更有效地探索广泛的联邦学习解决方案，还突出了需要进一步研究的领域。最终，这项调查通过描绘联邦学习在金融安全领域的现状，并提出未来研究的方向，为联邦学习的研究做出了贡献。

本文其余部分的结构安排如下。第二部分回顾了先前的综述，并为我们的研究奠定了背景。第三部分描述了监管和合规风险的分类建议。第四部分介绍了联邦学习在金融领域面临的实际挑战。第五部分简要讨论了联邦学习在金融领域的伦理和社会影响。最后，第六部分探讨了联邦学习在金融安全领域未来可能的应用实践，第七部分总结了本文的内容。

II. 背景与基础

机器学习（ML）和人工智能（AI）如今已比以往任何时候都更深入地融入我们的日常生活。电视上有关于人工智能的广告，一些企业依靠人工智能运营，而最引人注目的是像 ChatGPT 这样的大型语言模型（LLM）引发了人工智能不仅在研究领域，而且在众多行业乃至日常生活中应用的革命。

金融服务、银行业和保险业仍是利用机器学习潜力巨大的重要领域之一，这得益于丰富的数据和创新算法[11]。实际上，该技术已在风险建模、股票投资组合管理、算法交易和欺诈检测等方面得到了迅速发展。然而，传统的机器学习方法往往依赖于集中式数据收集，这引发了有关隐私、安全和监管合规的严重担忧。集中敏感的金融数据会增加数据泄露的风险，由于法律限制，也限制了机构之间的数据共享，并且使符合《通用数据保护条例》（GDPR）等法规变得复杂[17]。此外，传统机器学习模型的“黑箱”特性使得对其输出和内部操作的分析困难重重，从而阻碍了其在实际中的应用和推广[11]。

A. 联邦学习

联邦学习（FL）是传统机器学习的一种替代方案，它能让多个机构在不转移原始数据的情况下协同训练一个共享模型。在这个去中心化的框架中，每个参与者（如银行或金融机构）都在本地数据集上训练模型，并生成模型更新（如梯度或权重）。服务器使用诸如联邦平均[14]之类的算法汇总所有参与者的更新，以更新全局模型，然后在后续轮次中将该全局模型重新分发给参与者以进行进一步训练。此过程会一直重复，直到全局模型收敛。

为了进一步增强隐私和安全性，安全聚合[12]和差分隐私[13]通常被纳入联邦学习系统。安全聚合通过使用加密技术来组合更新，确保单个模型更新保持机密，只有最终的聚合结果可见。这使得任何单个更新都无法追溯到参与者。另一方面，差分隐私在更新共享之前向其引入高斯噪声。这种技术提供了正式的隐私保证，从共享模型中推断出任何单个数据点的敏感信息在数学上几乎不可能。这些防御措施共同作用，使联邦学习成为金融等敏感行业的稳健、保护隐私的方法。这使得金融机构能够在欺诈检测、风险评估和贷款审批等领域更有效地合作，同时不违反数据保护法[2]。

B. 先前的调查

当前的调查研究已经探讨了联邦学习领域内的进展、挑战和威胁。实际上，[1] 专门针对联邦学习中的安全威胁进行了研究，包括后门攻击、拜占庭攻击和对抗性攻击。这项工作对于揭示去中心化学习系统所存在的漏洞以及正在开发的应对措施具有重要价值。然而，其研究范围仍然较为宽泛，未能深入探讨诸如金融等特定领域的考量因素。

应用程序以及这些应用程序可能带来的规定和风险。

[35] 提供了另一项全面的调查，对联邦学习的挑战、设计和应用领域进行了全面回顾。他们根据核心系统挑战以及新兴的聚合和个性化技术对先前的工作进行了分类。然而，他们的调查主要侧重于联邦学习在医疗保健、移动设备和物联网等领域的应用。实际上，他们在调查中完全未涉及曝光分类，而我们认为这在金融应用中极为重要。

在已调研的文献中，没有一篇探讨如何对联邦学习框架进行定制以满足金融监管的严格要求、隐私保护以及风险分类的需求，这些需求要求模型必须准确、可解释甚至可审计。虽然有一些研究涉及联邦学习中的普遍统计异质性和个性化问题，但它们并未将这些挑战与金融领域所面临的潜在影响联系起来，比如信用评分模型中的偏差或贷款审批系统的对抗性操纵。

这项工作旨在填补联邦学习在金融应用这一被忽视领域中的空白。本综述着重探讨了联邦学习如何适应金融应用中不同程度的风险敞口。通过这样做，研究人员可以为在金融领域部署联邦学习提供一个框架。

III. 监管与合规风险暴露分类

本节根据联邦学习（FL）应用所面临的监管和合规风险对其进行分类。监管和合规风险是指机构因数据保护等不良行为或未能遵守内部政策或法律法规而面临潜在法律或监管制裁、声誉受损以及财务损失的风险[38]。合规风险是指由于不合规而可能给机构带来监管、财务或声誉损失的事件[38]。下面我们将讨论不同级别的监管和合规风险，并在每个级别下介绍不同的 FL 应用，同时阐述其关键方面和相关挑战。本节末尾的表 I 对这些应用进行了总结。

A. 低暴露

低风险应用的特点是几乎不受即时监管监督，其合规义务主要基于内部性质或自愿采用的行为准则[38]。这类应用通常涉及个人决策支持系统，模型输出用于指导长期决策，例如信用风险评估[15]或协作投资组合优化[16]。通常情况下，内部政策或最佳实践的监督可能会带来声誉风险，但受到法律制裁的可能性和影响都很小[38]。

*1)信用风险评估:*信用风险评估是联邦学习在金融领域中一个易于理解的低风险但影响重大的应用实例。最近的一项研究提出了一种联邦学习原型系统，多个金融机构能够在此系统中协同预测抵押贷款违约风险，而无需共享原始数据[15]。研究人员使用了房地美单户贷款级别数据集以及美国全国层面的经济指标，如拖欠率、冲销率和利率水平[15]，对 14 家模拟金融机构进行了时间序列 LSTM 模型的训练。在联邦学习架构和 FedAvg 的假设下，该研究发现数据的本地性和隐私得到了保护，同时较小的金融机构（数据集较小）也能从共享的见解中获益。在实验中，测试了五种场景，包括有和没有主要贡献者的设置。本研究的实证结果表明，联邦学习（FL）模型始终优于本地（单个金融机构）和集中式模型，其准确率达到了 99.04%，F1 分数为 98.22%，而本地模型的准确率为 95.04%，F1 分数为 92.65%，即便排除了最大的数据贡献者也是如此。

虽然这些数字展示了联邦学习的潜力，但近乎完美的表现可能会引发对其在当今世界有效性的质疑。该实验依赖于特定条件下整理的历史抵押贷款数据（2006 至 2009 年的抵押贷款危机），这可能无法反映当今更为多样的信贷环境。尽管排除主要数据提供者并未影响性能，但在现实世界中，联邦学习网络可能会因数据质量参差不齐或客户退出而出现更大的波动。不过，该研究仍具前景，但应将其视为乐观的上限而非确定的结果。

这些发现表明，联邦学习具有强大的稳健性和可扩展性，同时还能保持合规性。该研究进一步强调，模型性能与数据量密切相关，突显了小型机构之间开展合作的价值。这项工作通过使用真实的抵押贷款组合对联邦学习在信用风险建模中的应用进行了实证演示，表明联邦学习在不损害隐私的情况下能够提高风险评估的准确性。

*2)协作投资组合优化:*协作投资组合优化是联邦学习在金融领域中另一个有趣的低风险应用，它使金融机构能够在保护数据隐私的同时改进投资策略。2024 年 12 月进行的一项研究探讨了将联邦学习应用于投资组合优化过程的概念，该过程传统上依赖于受数据碎片化和监管限制的集中式模型[16]。作者将联邦学习视为一种解决方案，使多个机构能够在本地数据集上共同训练本地模型，从而保护专有交易数据、客户资料和风险指标的机密性。与风险评估研究[15]类似，该研究表明，对于数据有限的机构而言，协作尤其有益，因为它使它们能够利用市场的宏观视角，同时又不损害其利益。

符合诸如《通用数据保护条例》[17] 或《加州消费者隐私法》[18] 等法规。

本研究设计了一个模拟框架，在该框架中，多个机构在不共享原始数据的情况下协同训练优化模型。每个机构都基于现代投资组合理论（MPT）[19] 在本地优化投资组合，而全局模型则通过 FedAvg 迭代权重聚合的方式进行更新。所提出的架构通过允许灵活的聚合技术来支持不同的数据格式。重要的是，作者通过分散训练工作负载和实现投资组合更新的实时适应性，解决了数据异质性和计算复杂性等挑战。

与风险评估研究[15]不同，本研究未提供实验指标或基准比较，但通过展示在投资组合管理中实施联邦学习的概念和技术框架，做出了重大贡献。它突显了联邦学习如何增强模型的稳健性、模拟多样的市场状况以及降低系统性风险[16]。与传统的机器学习方法相比，所提出的联邦学习模型在不牺牲投资组合决策质量的前提下，提供了可扩展性、隐私保护和抗风险能力；为未来的实证研究奠定了基础，鼓励在投资组合管理中采用保护隐私的协作优化方法。

B. 中度暴露

中等风险的应用涉及监管义务，通常需要遵守适用于该应用的法律、法规、规则和行为准则[38]。这种风险通常会导致制裁、经济损失，最重要的是会增加监控和纠正措施[38]。这类应用通常会分析敏感数据，如收入、信用行为、就业历史和债务状况。对于此类预测，传统的机器学习方法会引发数据泄露、缺乏透明度以及对动态客户资料缺乏灵活性等问题。联邦学习（FL）提供了一种有前景的替代方案，它能够在不共享原始数据的情况下，实现跨多个金融机构的预测模型的分散式训练。

2024 年 12 月发表的一项研究提出了一种用于动态客户贷款预测的联邦机器学习与可解释人工智能（FML-XAI）框架[20]。该框架的可解释人工智能（XAI）部分通过利用 SHAP[21] 和 LIME[22] 技术，旨在为诸如信用评分、债务收入比和收入等影响模型决策的关键因素提供可解释的见解，以期建立客户信任。该研究直接解决了以下几项研究空白：

- 隐私与透明度：FML 缺乏可解释性。XAI 缺乏隐私保护。
- 动态数据处理：大多数研究依赖于静态数据，这在实际应用中往往难以应对。
- 可扩展性和效率：现有的 FML 系统不具备可扩展性，通信效率也不高。
- 特定领域的需求：金融应用程序需要符合监管规定并赢得客户信任，而这些方面在 FML 或 XAI 中均未得到解决。

为解决这些问题，作者们构建了自己的框架[20]，并展示了一种解决方案。该框架通过实时数据漂移[36]来应对适应性问题，因为客户资料会因收入、就业、消费模式和信用行为的变化而不断变化。通过增量学习和在线联邦学习，所提出的框架使本地模型能够融入新数据，同时全局模型不断演进以理解新趋势，从而保持预测的相关性。除了具备适应性，该框架还通过联邦学习（FML）确保敏感客户数据不会离开任何金融机构，从而提供强大的隐私保障。框架还通过使用可解释人工智能（XAI）技术为模型预测提供可解释的说明来解决透明度问题。在实验中，作者展示了该框架的可扩展性和通信效率。通过使用FedAvg以及可选的差分隐私技术，他们的系统能够支持在能力各异、客户群体不同的各类金融机构中部署。在他们的研究结果中，模型的准确率在联邦学习的各轮次中从 84% 提升到了 92%，而通信成本仍处于可控范围；这证明了该框架在非独立同分布数据集上具有良好的泛化能力，并且能够高效扩展以适应实际部署。简而言之，通过将 FML 和 XAI 相结合，他们所提出的框架最终增强了隐私保护、可解释性、适应性和可扩展性，使其成为现代贷款审批系统的理想选择。

C. 高曝光

高风险应用出现在监管严格的领域，通常不仅面临监管和合规风险，还存在诚信风险，可能需要持续监测监管环境的变化，以防止遭受严厉的法律制裁、重大经济损失甚至声誉损害[38]。这些应用通常涉及实时欺诈检测[7]、[8]、保障金融交易安全[23]，甚至反洗钱（AML）[23]、[24]。联邦学习已成为这一研究领域的焦点，它能够在保护隐私的同时实现协作智能。

1) 反洗钱：反洗钱（AML）合规是指金融机构遵循的法律和监管程序，旨在发现、预防和报告旨在掩盖非法所得资金来源的可疑活动[25]。反洗钱框架通常涉及对大量金融交易进行监控，以发现异常行为。然而，现有的反洗钱系统往往受限于其对集中式模型的依赖，这些模型受制于数据不完整，通常会产生误报；据估计，超过 98% 的警报都是误报，导致运营成本增加[24]。与许多其他金融应用一样，反洗钱也存在隐私监管方面的顾虑，这使得金融机构无法共享敏感的客户交易数据。

联邦学习作为一种可能的解决方案已浮出水面，它能让多家金融机构在分散的数据上协同训练机器学习模型。

在保护数据隐私的同时，通过接触各种洗钱模式来提高模型性能。如图 2 所示，洗钱者先将非法所得的“脏钱”存入合法的金融系统。然而，为了逃避侦查，犯罪分子可能会将这些资金分散到多个不同的来源。这些来源可能是国外银行账户、清白的亲属、空壳公司，甚至多个国内银行账户。一旦资金通过这些来源进行了层层转移，犯罪分子就能够将这些“干净”的钱重新投入经济活动，而不会因非法获取资金而受到刑事追究。直观地说，联邦学习可以通过利用联合智能做出更明智的决策，直接打击洗钱的层层转移手段。例如，摩根大通可以与其他国内银行以及像法国巴黎银行这样的国外银行合作，以获取更广泛的资金流向信息。

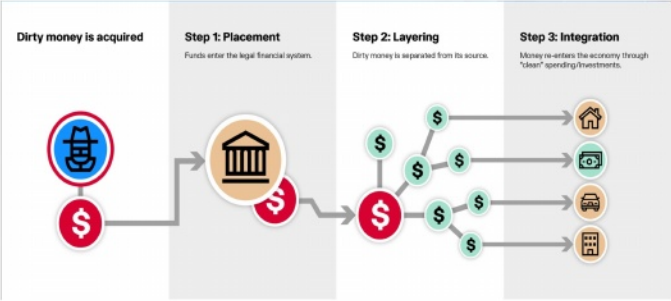

图 2. 洗钱方案的可视化表示。图片来源：Linkurious，网址：https://linkurious.com/money-laundering-schemes/

最近的一项研究[24]提出了一种基于联邦学习的新型AML检测框架，解决了传统系统的不足。该研究受联邦人工智能使能器（FATE）框架和SecureBoost[37]的启发，引入了一个系统，其中五个虚拟存款银行分别独立训练本地模型，并通过中央服务器进行协调，而无需交换数据。每个银行使用基于过滤器的特征选择方法，利用XGBoost在本地数据上训练模型，以突出相关交易特征[25]。模型经过加密，并采用差分隐私技术进行增强，以确保模型更新的安全性。该架构通过使用隐私损失（ε）和意外数据泄露风险（δ）进行正式的隐私风险量化，并采用FedAvg协议聚合模型权重。

在实验中，作者们讨论了实验结果，这些结果表明他们的方法具有实用性和高效性。实验使用了包含 600 万笔移动交易的 PaySim 数据集，其中既有真实交易也有欺诈行为。集中式基准模型的准确率为 0.99%，误报率为 0.1%。分类报告进一步表明其得分近乎完美，良性交易的 F1 分数为 1.0，恶意交易的 F1 分数为 0.99。联邦模型产生的结果与基准模型相似，偶尔性能会略有下降，但仍能接近 1.0 的 F1 分数。尽管这些发现表明联邦学习能够在保护隐私的同时达到集中式模型的性能，但应谨慎解读。PaySim 数据集是合成的且高度受控，这可能比现实世界中反洗钱所遇到的嘈杂、不平衡甚至对抗性数据集带来更理想的结果。此外，联邦模型相对于集中式基准模型的微小改进表明，联邦学习的价值更多在于实现跨机构的隐私保护协作，而非单纯提高准确性。监管机构也可能对近乎完美的绩效指标持怀疑态度，因为这些指标往往是过度拟合的结果。

尽管联邦学习（FL）方法在显著降低误报率方面似乎并无用处，但重要的是要认识到这项研究的实际意义。这些发现证实了联邦学习能够在保护数据隐私、减少误报以及解决模型可扩展性问题的同时保持检测的准确性。最终，这种方法表明联邦学习在反洗钱合规的未来具有潜力，能够降低运营成本并促进协作，同时不泄露敏感数据。

*2)基于区块*链的联邦学习中的*欺诈检测:*区块链是一种去中心化且分布式的账本系统，以防篡改和透明的方式在多个节点间记录交易[26]。每笔交易都被分组到一个通过加密技术保护的区块中，并与前一个区块相连接，从而形成一条永久的链。一旦数据被写入区块链，除非获得整个网络的共识，否则无法更改。在金融安全的背景下，这种不可变性确保了诸如交易、模型更新或访问权限等所有交互都是可验证的，并被永久记录。

传统的欺诈检测模型通常依赖于集中式数据聚合，这带来了隐私风险和监管挑战。文献[8]提出了一种综合创新框架，该框架利用联邦学习（FL）与区块链技术相结合，以增强金融机构的安全性和完整性。所提出的框架利用区块链的无信任环境和智能合约功能来提高联邦学习过程的安全性和监管性。智能合约是部署在区块链上的可编程规则，能够自动执行访问控制、身份验证和模型共享策略[8]、[26]。这消除了对中间人或中央权威机构的需求，降低了操纵、数据泄露或未经授权访问的风险。区块链层通过智能合约确保联邦学习系统中的每个机构都遵循预定义的协议，从而实现安全且可问责的合作。

这种基于区块链的联邦学习架构旨在检测金融交易中的欺诈行为，包括信用卡欺诈和申请欺诈。智能合约对客户进行身份验证，授权模型提交，管理版本控制，并安全地同步本地和全局模型[8]。该系统确保联邦网络中的每次更新都可追溯。

表一

联邦学习在金融领域的应用概述

应用程序	暴露水平	报告的业绩	隐私技术	关键限制
信用风险评估	低	准确率为 99.04%，F1 值为 98.22，而本地模型的准确率为 95.04%，F1 值为 92.65%	联邦平均算法	与抵押贷款危机数据（2006 年至 2009 年）相关的结果
协作投资组合优化	低	跨机构的 FedAvg 聚合概念框架	联邦平均算法 + 安全聚合	没有量化基准；主要是理论性的
贷款批准	适度的	在联邦学习的各轮中，准确率从 84% 提升到了 92%	联邦平均算法 + 差分隐私 + 可解释人工智能（SHAP/LIME）	验证仅限于模拟；异构数据带来的挑战
安全金融交易	高的	保护隐私的交易验证	联邦平均算法 + 加密	性能未完全发挥
反洗钱	高的	集中式性能与联邦式性能相当，但承诺实现隐私保护和准确性保持的协作	FATE + 安全多方计算（SecureBoost）+ 差分隐私	合成数据集（PaySim）；在实际操作中不太可能获得“完美”分数
区块链欺诈检测	高的	使用联邦学习后检测精度提高	差分隐私	高误报率会推高合规成本

该系统具备可用性、防篡改性和合规性。作者使用来自 Kaggle 的合成数据集对所提出的系统进行了验证，该数据集模拟了 180 万笔真实世界中的信用卡交易。数据包含 20 个特征，其中选取了 15 个。评估了六种机器学习模型（K 近邻、支持向量机、决策树、朴素贝叶斯、逻辑回归和随机森林），该框架在识别欺诈行为的同时保持了隐私标准，表现出了良好的性能。通过将区块链的完整性与联邦学习的隐私保护模型训练相结合，该框架使机构能够在不共享敏感数据的情况下共享知识。

IV. 金融领域中的外语挑战

正如本调查报告所讨论的那样，联邦学习为金融行业提供了极具吸引力的优势，尤其是在保护私人数据的同时实现协作智能方面。然而，其应用并非一帆风顺。联邦系统必须考虑到在金融环境中因决策结果风险高和数据环境敏感而被放大的独特限制和风险。

本节将联邦学习在金融领域面临的关键挑战分为三个领域：（1）与数据异质性和通信相关的技术限制；（2）尽管增强了隐私保护但仍易受安全威胁；（3）影响部署和采用的监管及信任相关问题。

A. 数据异构性和通信开销

联邦学习系统面临的最大障碍之一是数据异质性和非独立同分布。金融机构服务不同的人群，在不同的地区运营，并处理各种各样的交易类型，这导致了数据分布的异质性。这会破坏全局模型的收敛性，并降低泛化性能，使得难以生成在所有客户中表现一致的稳健模型。

通信开销和可扩展性带来了额外的担忧。联邦学习依赖于客户端与中央服务器之间模型参数的反复交换。在跨机构的环境中，由于金融机构可能具有不同的基础设施或带宽能力，通信可能会变得资源密集型，并引入延迟，从而限制了联邦学习在本调查中提到的时间敏感型金融任务中的适用性。

B. 安全威胁与隐私漏洞

最重要的是，尽管联邦学习在设计上提高了隐私保护水平，但它仍然容易受到诸如模型投毒[1]和后门攻击[5]等安全威胁。在模型投毒中，恶意参与者创建并提交经过篡改的模型更新，这些更新在聚合后会降低整体性能或在全局模型中注入隐藏目标。其中一种特殊形式是后门攻击，攻击者在其本地模型上使用被篡改的数据进行训练，或者更改权重，使得全局模型在处理常规输入时表现正常，但在受到特定模式[5]或输入（例如涉及特定账户号码的交易）触发时产生攻击者指定的输出（错误分类涉及特定账户号码的交易）。由于安全聚合会掩盖单个更新以保护隐私，这也无意中隐藏了恶意行为，因此这些攻击可能难以被发现。在金融安全的背景下，攻击者可能会操纵欺诈检测模型，使其始终忽略与特定触发因素（如其账户号码）相关的活动，如洗钱。这使得攻击者能够利用欺诈检测和洗钱等机制，同时保持隐蔽。

C. 监管障碍与信任

此外，合规性问题也是一个难题。差分隐私等技术提供了正式的隐私保障，但要使其与金融行业的法规相契合可能会变得非常繁琐和复杂。监管机构通常要求具备透明度和用户同意，而当前的联邦学习系统可能无法完全满足这些要求。

最后，在金融应用中，可解释性和信任至关重要，因为模型的决策会影响金融决策、贷款审批和欺诈检测。如果让人工智能模型在没有任何解释的情况下做出如此重要的决策，这是不可接受的。

这个问题的答案阻碍了 FL 在金融领域的部署，甚至可能破坏用户信任。

V. 金融领域中金融科技的伦理与社会影响

虽然联邦学习框架的技术性能前景广阔，但其在金融领域的部署还引发了更广泛的伦理和社会考量，这些考量超出了准确率等技术指标的范畴。

透明度和可解释性：当前的金融监管法规通常要求风险模型能够向审计员、监管机构以及更重要的终端用户进行解释。依赖深度学习的联邦学习框架可能会提高准确性，但存在重现“黑箱”问题的风险。缺乏可解释性可能会削弱客户信任，尤其是在信用评分或贷款审批等应用中，因为这些应用关系到个人的生计。

公平性与偏见：信用风险数据集往往反映出历史偏见，例如不同地区在抵押贷款审批方面的差异。如果参与的机构提供的数据不均衡，联邦学习可能会放大这些偏见。若不进行公平性审计，联邦学习带来的益处可能会无意中加剧歧视，从而产生伦理风险。

责任：与任何机器学习技术一样，联邦学习系统也会出错，责任归属问题可能会变得复杂。如果多家银行合作开发一个共享模型，那么在反洗钱中出现的误报或信贷审批不佳等问题的责任可能会由所有参与机构甚至联邦学习平台共同承担。这种责任的分散不仅带来了伦理挑战，还带来了法律挑战。

应对这些挑战不仅需要诸如可解释人工智能和公平性感知训练等技术解决方案，还需要新的法规来重新定义协作系统中的责任归属。

VI. 金融安全领域中的未来金融科技

应对这些挑战需要针对金融行业需求对联邦学习框架进行改进。

A. 区块链-联邦学习集成

一个特别有前景的方向是将联邦学习与区块链技术和智能合约相结合，如第 III-C2 节所探讨的那样。区块链的不可篡改账本为模型更新提供了一个安全且可解释的记录，增强了审计性和各利益相关方之间的信任。此外，智能合约可用于自动执行合规性和参与规则，减少人工监督的需求，并将人为错误或恶意攻击的可能性降至最低。

B. 量子计算与联邦学习

随着量子计算的发展和壮大，当前联邦学习系统中使用的传统加密方法在未来数年或数十年内可能会过时。因此，开发量子安全的联邦学习框架变得至关重要。量子计算机利用诸如叠加和纠缠等特性[28]，能够比传统计算机快得多地执行复杂计算。这种能力为金融分析模拟中的风险分析和快速投资组合优化等高级应用打开了大门。然而，它也威胁到诸如 RSA 和椭圆曲线加密等传统加密协议，而这些协议是 FL 通信和数据隐私安全的基础[10]。

除了安全性之外，量子计算还能提高联邦学习本身的计算效率。量子机器学习算法可以适应联邦学习环境，使客户端能够更快地进行本地训练或优化任务，这可能会减少收敛时间和通信轮次。尽管这仍是一个活跃的研究领域，但混合经典-量子联邦学习架构[10]未来可能会发挥作用，尤其是在高频交易中，速度和准确性至关重要。然而，这些进步需要量子计算在基础设施和实际应用方面取得重大发展，而这还需要很多年才能实现。到 2025 年，谷歌[39]、IBM[40]和微软[41]等几家科技公司在量子计算领域取得了重大进展，但金融机构距离做好量子计算的准备还很遥远。最终，量子计算在联邦学习中的应用是将量子计算的速度与联邦学习的隐私保障相结合的绝佳方式，但这需要在两个研究领域都取得重大进展。

VII. 结论

联邦学习代表了金融机构在机器学习模型合作方面的一种转变，能够在保护数据隐私和遵守监管规定的同时进行协作。通过实现去中心化的模型训练，联邦学习降低了与集中式数据相关的风险，并为金融领域安全、可扩展的人工智能系统创造了机会。对不同风险敞口水平（从信用评分到欺诈检测）的分析表明，联邦学习具有广泛的应用场景和对现实世界产生影响的潜力。然而，数据异质性、对抗性威胁以及缺乏可解释性等问题仍然阻碍着其部署。此外，与监管规定的整合需求以及用户对信任和透明度的要求也必须得到解决。

特别是，诸如销售点系统和移动银行设备等物联网支持的金融终端的兴起，使得保护隐私的机器学习解决方案成为必要。跨设备联邦学习为满足这些需求提供了一个极具吸引力的解决方案，允许模型直接从终端学习，而无需暴露敏感数据。展望未来，联邦学习与区块链技术的融合为金融机构之间的可验证协作提供了令人兴奋的机会。此外，量子计算的兴起既带来了威胁也带来了机遇。量子安全的联邦学习架构有望实现指数级的计算速度提升。随着这些技术的发展，联邦学习在金融领域的未来将取决于机器学习、密码学、金融监管和分布式学习等多方面的努力。有了正确的框架

只要具备适当的保障措施，联邦学习（FL）就能成为安全、智能且合乎道德的金融创新的基石。

参考文献

[1] Y. Feng et al., "A survey of security threats in federated learning," *ArXiv preprint arXiv:2303.05383*, 2023.

[2] Y. Wang, "Ethical considerations of AI in financial decision," *ArXiv preprint arXiv:2312.13434*, 2023.

[3] NVIDIA, "NVFLARE Documentation - Feder-ated Learning Introduction," [Online]. Available: https://nvflare.readthedocs.io/en/2.4/fl introduction.html

[4] F. Boenisch et al., "When the Curious Abandon Honesty: Federated Learning Is Not Private," in *Proceedings of the 2021 IEEE Symposium on Security and Privacy (SP)*, 2021, pp. 162–179.

[5] E. Bagdasaryan et al., "How to backdoor federated learning," in *Proceedings of the 23rd International Conference on Artificial Intelligence and Statistics*, 2020, pp. 2938–2948.

[6] P. Durgapal, "A Comprehensive Distributed Framework for Cross-silo Federated Learning using Blockchain," *ArXiv preprint arXiv:2304 01338*, 2023.

[7] S. Abanilla, "Towards Privacy Preserving Financial Fraud Detection," *ArXiv preprint arXiv:2304.07343*, 2023.

[8] T. Khanzada et al., "Enhancing security in financial transactions: a novel blockchain-based federated learning framework for detecting counterfeit data in fintech," *PeerJ Computer Science*, vol. 10, pp. e2280, Sep. 2024, doi: 10.7717/peerj-cs.2280.

[9] S. Sharma and K. Guleria, "A Federated Learning Mechanism for Preserving Security of Sensitive Data," in *2023 4th International Conference on Data Analytics for Business and Industry (ICDABI)*, Oct. 2023, pp. 1–5, doi: 10. 1109/ICDABI60145.2023.10629264.

[10] A. Akin and N. Hou, "The Future of AI in Fintech: Exploring the Potential of Quantum Computing and Federated Learning for Advanced Financial Services," *ArXiv preprint arXiv:2401.00311*, 2023.

[11] J. Sen, "Machine Learning in Finance-Emerging Trends and Chal-lenges," *International Journal of Computer Applications*, vol. 163, no. 10, pp. 39–43, 2017.

[12] K. Bonawitz et al., "Practical Secure Aggregation for Privacy-Preserving Machine Learning," in *Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security*, 2017, pp. 1175– 1191.

[13] H. B. McMahan et al., "Learning Differentially Private Recurrent Language Models," in *Proceedings of the 31st International Conference on Neural Information Processing Systems*, 2017, pp. 6308–6316.

[14] H. B. McMahan et al., "Communication-Efficient Learning of Deep Networks from Decentralized Data," in *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics*, 2017, pp. 1273–1282.

[15] C. M. Lee, "Federated Learning for Credit Risk Assessment," *ArXiv preprint arXiv:2011.13158*, 2020.

[16] J. Paul, "Federated Learning in Collaborative Portfolio Optimization," *Available at SSRN 4670588*, 2024.

[17] European Parliament and Council, "Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data, and repealing Directive 95/46/EC (General Data Protection Regulation)," *Official Journal of the European Union*, vol. 59, no. L 119, pp. 1–88, 2016. [Online]. Available: https://gdpr-info.eu

[18] California Office of the Attorney General, "California Consumer Privacy Act (CCPA)," [Online]. Available: https://oag.ca.gov/privacy/ccpa

[19] Investopedia, "Modern Portfolio Theory (MPT)," [Online]. Available: https://www.investopedia.com/terms/m/modernportfoliotheory.asp

[20] A. N. Kumar, "Federated Machine Learning and Explainable AI for Dynamic Customer Loan Prediction Analysis.

[21] S. M. Lundberg and S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," in *Proceedings of the 31st International Conference on Neural Information Processing Systems*, 2017, pp. 4765–4774.

[22] M. T. Ribeiro, S. Singh, and C. Guestrin, "Why Should I Trust You? Explaining the Predictions of Any Classifier," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 1135–1144.

[23] W. Joseph, "Federated Learning for Secure Financial Transactions," *Available at SSRN 4670589*, 2025.

[24] B. Guembe et al., "A Federated Machine Learning Approaches For Anti-Money Laundering Detection," in *Proceedings of the International Conference on Information Systems and Emerging Technologies (ICISET)*, 2023, pp. 1–13.

[25] Financial Industry Regulatory Authority (FINRA), "Anti-Money Laundering (AML)," [Online]. Available: https://www.finra.org/rules-guidance/key-topics/aml

[26] Investopedia, Blockchain, [Online]. Available: https://www.investopedia.com/terms/b/blockchain.asp

[27] T. Li et al., "FAIR RESOURCE ALLOCATION IN FEDERATED LEARNING," in *Proceedings of the 9th International Conference on Learning Representations*, 2021.

[28] Quantum Inspire, "Superposition and Entanglement," [Online]. Available: https://www.quantum-inspire.com/kbase/superposition-and-entanglement/

[29] L. Ventures, "AI's Impact on Financial Fraud: A JP Morgan Case Study," lum.ventures, 2024. [Online]. Available: https://www.lum.ventures/blog/ais-impact-on-financial-fraud-jp-morgan-case-study

[30] Redress Compliance, "AI Case Study: AI-Powered Employee Expense Fraud Detection at Visa," redresscompliance.com, 2024. [Online]. Available: https://redresscompliance.com/ai-case-study-ai-powered-employee-expense-fraud-detection-at-visa/

[31] Teradata, "Danske Bank Saves Millions Fighting Fraud With Deep Learning and AI," *teradata.com*. [Case Study]

[32] Redress Compliance, "AI Case Study: AI-Powered Automated Loan Processing at Wells Fargo," *redresscompliance.com*, 2024. [Online]. Available: https://redresscompliance.com/ai-case-study-ai-powered-automated-loan-processing-at-wells-fargo/

[33] Redress Compliance, "AI Case Study: AI for Stock Market Analysis - Bloomberg Terminal," *redresscompliance.com*, 2024. [Online]. Available: https://redresscompliance. com/ai-case-study-ai-for-stock-market-analysis-bloomberg-terminal/

[34] EazyBankLoan, "The Influence of Economic Conditions on Loan Approval and Rates," eazybankloan.com. [Online]. Available: https://www. eazybankloan. com/blog-detail/The-Influence-of-Economic-Conditions-on-Loan-Approval-and-Rates

[35] K. M. J. Rahman et al., "Challenges, Applications and Design Aspects of Federated Learning: A Survey," IEEE Access, vol. 9, pp. 124682-124700, 2021.

[36] Dataiku, "Managing Data Drift: Ensuring Model Performance Over Time," blog.dataiku.com, 2023. [Online]. Available: https://blog.dataiku. com/managing-data-drift-ensuring-model-

performance-over-time

[37] K. Cheng et al., "SecureBoost: A Lossless Federated Learning Frame work," arXiv preprint arXiv:1901.08755, 2019.

[38] P. Benedek and F. Bogn´ar, "Compliance Risk Assessment - Results of a Comprehensive Literature Review," *Acta Polytechnica Hungarica*, vol. 21, no. 6, pp. 243-258, 2024.

[39] Google, "Quantum AI," *quantumai.google*, 2025. [Online]. Available: https://quantumai.google/

[40] IBM, "IBM Quantum," *quantum.ibm.com*, 2025. [Online]. Available: https://quantum.ibm.com/

[41] Microsoft, "Azure Quantum," *quantum.microsoft.com*, 2025. [Online]. Available: https://quantum.microsoft.com/